HOCHSCHULE KOBLENZ
UNIVERSITY OF APPLIED SCIENCES

Bachelorarbeit

Koblenz, 26. Juni 2026

Analyse der Nutzbarkeit von Large Language Models(LLMs) in Thematisch fokussierten Expertensystem in Verbindung mit Text-Retrieval Methode

Name: Emmanuel Talom Goumlepoue

Mat.-Nr.: 552 772

Hochschule	Koblenz
Fachbereich	Ingenieurwesen
Studiengang	Bachelor of Engineering Informationstechnik

Bearbeitungszeitraum: 01.04.2026 - 23.06.2026

Betreuer:	Prof. Dr. Dr. Sergej Sizov
Firmen-Betreuer:	evtl. streichen
Erstgutachter:	
Zweitgutachter:	

Selbständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbständig und ohne unerlaubte fremde Hilfe angefertigt, keine anderen als die angegebenen Quellen und Hilfsmittel verwendet und die den verwendeten Quellen und Hilfsmitteln wörtlich oder inhaltlich entnommenen Stellen als solche kenntlich gemacht habe.

(Ort, Datum)	(Unterschrift)

Kurzfassung

Zusammenfassung: Diese Arbeit untersucht die Nutzbarkeit von Large Language Models (LLMs) in einem thematisch fokussierten Expertensystem unter Einsatz moderner Text-Retrieval-Methoden. Ausgangspunkt ist die Problematik, dass LLMs zwar leistungsfähig in der Generierung natürlicher Sprache sind, jedoch zu sogenannten Halluzinationen neigen und somit nicht zuverlässig ausschließlich faktenbasierte Antworten liefern.

Zur Lösung dieses Problems wird ein Retrieval-Augmented-Generation-Ansatz (RAG) verfolgt, bei dem relevante Informationen aus einer externen Wissensbasis abgerufen und als Kontext für die Antwortgenerierung verwendet werden. Die Wissensbasis wird mithilfe von Elasticsearch realisiert, wobei eine Hybrid Search zum Einsatz kommt, die sowohl eine lexikalische Suche mittels BM25 als auch eine semantische Vektorsuche kombiniert. Ziel ist es, die jeweils relevantesten Textabschnitte (Top-k) zu identifizieren und dem LLM bereitzustellen.

Im Rahmen der Arbeit wird ein vollständiges System entwickelt, das die Indexierung von Dokumenten, die Durchführung hybrider Suchanfragen sowie die Generierung kontextbasierter Antworten umfasst. Besonderer Wert wird darauf gelegt, dass die generierten Antworten ausschließlich auf den bereitgestellten Textabschnitten basieren und die entsprechenden Quellen transparent angegeben werden. Zudem wird ein Mechanismus implementiert, der erkennt, wenn keine ausreichenden Informationen vorliegen, und in solchen Fällen auf eine Antwort verzichtet.

Die Evaluation des Systems erfolgt anhand definierter Metriken zur Bewertung der Retrieval-Qualität sowie der inhaltlichen Korrektheit der generierten Antworten. Die Ergebnisse zeigen, dass die Kombination aus BM25 und Vektorsuche die Relevanz der Suchergebnisse verbessert und dadurch die Qualität der generierten Antworten signifikant erhöht. Gleichzeitig kann die Häufigkeit von Halluzinationen reduziert werden.

Die Arbeit leistet somit einen Beitrag zur Entwicklung verlässlicher und nachvollziehbarer KI-gestützter Expertensysteme und zeigt das Potenzial hybrider Retrieval-Methoden in Kombination mit Large Language Models auf.

Abstract

Abstract: This thesis investigates how Large Language Models (LLMs) can be integrated into a thematically focused expert system that utilises modern text retrieval methods. The starting point is the problem that, whilst LLMs are highly proficient at generating natural language, they are prone to so-called hallucinations and therefore cannot be considered reliable when it comes to providing exclusively fact-based answers.

A Retrieval-Augmented Generation (RAG) approach is adopted to solve this problem: it retrieves relevant information from an external knowledge base and uses it as context for generating the response. The knowledge base is implemented using Elasticsearch, employing a hybrid search that combines lexical search via BM25 with semantic vector search. The aim is to identify the most important text sections (Top-k) and make them available to the LLM.

This thesis designs a comprehensive system that encompasses document indexing, the execution of hybrid search queries, and the generation of context-based responses. It is of great importance that the responses generated are based solely on the text passages provided and that the sources are clearly cited. Furthermore, a mechanism is introduced that detects when the information is insufficient and, in such cases, does not provide a response.

To evaluate the system, established metrics are used to assess the retrieval quality and the factual accuracy of the generated responses. The results demonstrate that the relevance of search results is improved by combining BM25 and vector search, which significantly enhances the quality of the generated responses. Furthermore, it is possible to reduce the frequency of hallucinations.

The work thus contributes to the creation of reliable and transparent AI-supported expert systems and highlights the potential of hybrid retrieval methods in conjunction with large language models.

Inhaltsverzeichnis

Abbildungsverzeichnis **VI**

Tabellenverzeichnis **VII**

Abkürzungsverzeichnis **VIII**

1 Einleitung **1**

2 Theoretische Grundlagen **3**

2.1 Large Language Models (LLMs):Funktionsweise, Stärken und Schwächen . . . 3

2.2 Expertensysteme: Definition und Eigenschaften – Klassische vs. moderne Ansätze . . . 3

2.3 Information Retrieval: Grundlagen & BM25-Algorithmus . . . 4

2.4 Semantische Suche:Embeddings & Vektorraummodelle . . . 4

2.5 Hybrid Search: Kombination von BM25 und Vektorsuche – Vorteile & Herausforderungen . . . 5

2.6 Retrieval-Augmented Generation (RAG) . . . 5

3 Stand der Forschung zu LLMs in domänenspezifischen Expertensystemen mit Fokus auf RAG und Retrieval-Methoden **7**

3.1 Aktuelle Ansätze mit LLMs in Expertensystemen . . . 7

3.2 Einsatz von RAG in der Praxis . . . 7

3.3 Vergleich bestehender Retrieval-Methoden((BM25, Dense, Hybrid)) . . . 8

3.4 Forschungslücken und Herausforderungen . . . 9

4 Anforderungsanalyse und Systemkonzeption **10**

4.1 Methodisches Vorgehen . . . 10

4.2 Fachliche Anforderungen . . . 10

4.3 Technische Anforderungen . . . 11

4.4 Definition der User Stories . . . 11

4.5 Ableitung der Systemanforderungen . . . 14

4.6 Systemarchitektur . . . 15

4.7 Zusammenfassung . . . 15

5 Implementierung **16**

5.1 Datenaufbereitung und Chunking . . . 16

5.2 Hybride Suche . . . 17

5.3 Backend-Architektur mit FastAPI . . . 19

5.4 LLM-Integration und Prompting . . . 19

5.5 Antwortvalidierung 20
5.6 Frontend-Implementierung mit Streamlit 20
5.7 Konfiguration 21
5.8 Zusammenfassung 21

6 Evaluation **22**
6.1 Evaluationsmethodik 22
6.2 Evaluationsmethodik 22
6.3 Retrieval-Evaluation 24
6.3.1 Analyse der Hybrid-Suche 26
6.4 Ergebnisse der Antwortbewertung 26
6.4.1 Qualitative Analyse 27
6.5 Diskussion 28
6.6 Zusammenfassung 28

7 Diskussion **29**
7.1 Bewertung der Ergebnisse 29
7.2 Stärken und Schwächen des Systems 29
7.3 Limitationen 30

8 Fazit und Ausblick **31**
8.1 Fazit 31
8.2 Einschränkungen 32
8.3 Ausblick 32

A Literatur **33**

B Allgemeiner Anhang **34**

Abbildungsverzeichnis

5.1 Verarbeitung von PDF-Dokumenten zu Text-Chunks 17
5.2 Ablauf der hybriden Suche mit BM25, Vektorsuche und RRF 18
5.3 Ablauf einer Anfrage durch das Backend 19
5.4 Benutzeroberfläche des Systems 21
6.1 Precision@k und Recall@k für verschiedene Werte von k 25
6.2 Vergleich der Retrieval-Ergebnisse von BM25 und Vektorsuche für k=5 26
6.3 Bewertung der Antwortqualität durch ein LLM (Skala 1–5) 27

Tabellenverzeichnis

3.1 Vergleich bestehender Retrieval-Methoden 8
4.1 Zusammenhang zwischen User Stories und Systemkomponenten . . . 14

Abkürzungsverzeichnis

LLMs	Large Language Models
KI	Künstliche Intelligenz
RAG	Retrieval-Augmented Generation
BN25	Best Matching 25 (Rankingfunktion im Information Retrieval)

1 Einleitung

Die rasante Entwicklung von Large Language Models (LLMs) hat in den letzten Jahren beeindruckende Fortschritte in der automatisierten Verarbeitung natürlicher Sprache hervorgebracht. Weil sie in der Lage sind, komplexe Fragestellungen zu erfassen und sinnvolle Antworten darauf zu formulieren, finden fortschrittliche Modelle immer öfter Einsatz in wissensbasierten Anwendungen und Expertensystemen. Trotz dieser Fortschritte gibt es ein erhebliches Problem: Da die Inhalte von LLMs probabilistisch erstellt werden, können sie sogenannte Halluzinationen produzieren: Antworten, die zwar glaubwürdig wirken, aber nicht auf verifizierbaren Informationen beruhen.

In thematisch fokussierten Expertensystemen, in denen die Korrektheit und Nachvollziehbarkeit von Informationen entscheidend sind, stellt dieses Verhalten eine erhebliche Herausforderung dar. Klassische Expertensysteme basieren zwar auf strukturierten Wissensbasen und liefern nachvollziehbare Ergebnisse, sind jedoch häufig unflexibel und schwer skalierbar. Im Gegensatz dazu zeichnen sich LLMs durch eine hohe Flexibilität aus, allerdings auf Kosten der Verlässlichkeit.

Das Konzept der Retrieval-Augmented Generation (RAG) stellt einen vielversprechenden Ansatz dar, um die Stärken beider Ansätze zu kombinieren. Dabei werden externe Wissensquellen in den Generierungsprozess integriert, indem relevante Dokumente zunächst mithilfe von Information-Retrieval-Methoden identifiziert und anschließend als Kontext für die Antwortgenerierung verwendet werden. Moderne Suchsysteme wie Elasticsearch ermöglichen dabei eine sogenannte Hybrid Search, die sowohl lexikalische Verfahren (z.B. BM25) als auch semantische Vektorsuche kombiniert. Dadurch können sowohl exakte Wortübereinstimmungen als auch semantische Ähnlichkeiten berücksichtigt werden.

In diesem Zusammenhang besteht die zentrale Herausforderung darin, ein System zu entwickeln, das relevante Informationen zuverlässig identifiziert, die Antwortgenerierung strikt auf diese Informationen beschränkt und gleichzeitig transparente sowie nachvollziehbare Ergebnisse liefert. Darüber hinaus muss das System erkennen, wenn die vorhandenen Informationen nicht ausreichen, um eine Anfrage zu beantworten, und in solchen Fällen bewusst auf eine Antwort verzichten.

Vor diesem Hintergrund untersucht diese Arbeit die Nutzbarkeit von Large Language Models in einem thematisch fokussierten Expertensystem in Verbindung mit hybriden Retrieval-Methoden. Zu diesem Zweck wird ein System entwickelt, das Elasticsearch als Vektordatenbank nutzt, eine Kombination aus BM25-basierter Volltextsuche und semantischer Vektorsuche realisiert und die gewonnenen Ergebnisse gemeinsam mit einem LLM zur Beantwortung von Nutzeranfragen verwendet. Im Fokus stehen dabei die Qualität der generierten Antworten, die Minimierung von

Halluzinationen sowie die Gewährleistung der Nachvollziehbarkeit durch die Angabe der zugrunde liegenden Textpassagen.
Die Struktur der Arbeit ist wie folgt: In Kapitel 2 werden die theoretischen Grundlagen zu Large Language Models, Information Retrieval und Hybrid Search erläutert. Kapitel 3 gibt einen Überblick über den aktuellen Stand der Forschung. In Kapitel 4 wird die Systemarchitektur vorgestellt, während Kapitel 5 die Implementierung beschreibt. Kapitel 6 widmet sich der Evaluation des Systems, gefolgt von einer kritischen Diskussion der Ergebnisse in Kapitel 7. Abschließend werden in Kapitel 8 die zentralen Erkenntnisse zusammengefasst und ein Ausblick auf zukünftige Entwicklungen gegeben.

2 Theoretische Grundlagen

Dieses Kapitel führt die Konzepte ein, die für diese Arbeit wichtig sind. Zuerst werden Large Language Models (LLMs) erklärt, zusammen mit ihren größten Stärken und Schwächen. Anschließend werden Expertensysteme als Anwendungsbereich betrachtet, bevor die Grundlagen des Information Retrievals, der semantischen Suche, der Hybrid Search und von Retrieval-Augmented Generation (RAG) erklärt werden.

2.1 Large Language Models (LLMs):Funktionsweise, Stärken und Schwächen

Neuronale Netze, die auf großen Textmengen trainiert werden, sind die Grundlage für Large Language Models (LLMs), die somit in der Lage sind, eine Vielzahl von Aufgaben der natürlichen Sprachverarbeitung zu bewältigen [?] [?] [?],[?].Sie speichern Wissen in ihren Parametern („parametrisches Wissen“) und sind in der Lage, Texte zu generieren, Fragen zu beantworten oder Zusammenfassungen zu erstellen [?].Ihre Flexibilität bei einer Vielzahl von Aufgaben und die Fähigkeit zur Generalisierung sind große Stärken [?],[?].
Ein zentrales Problem ist jedoch das Phänomen der Halluzination: LLMs erzeugen plausible, aber faktisch falsche oder unbelegte Inhalte [?],[?],[?].Die Gründe dafür sind unter anderem veraltete Trainingsdaten, das Fehlen einer Anbindung an aktuelle Wissensquellen und Einschränkungen im Modell selbst [?] [?] [?].Selbst mit Retrieval-Augmented Generation (RAG) können Halluzinationen zwar verringert, aber nicht gänzlich beseitigt werden [?] [?].

2.2 Expertensysteme: Definition und Eigenschaften – Klassische vs. moderne Ansätze

Wissensbasierte Computersysteme, die menschliches Expertenwissen elektronisch darstellen und nutzen, um Probleme zu lösen, die normalerweise menschliche Intelligenz erfordern, sind Expertensysteme [?] [?] [?] [?]. Üblicherweise setzen sie sich aus einer Wissensbasis (Knowledge Base), einem Inferenzmechanismus (Inference Engine) und einer Benutzerschnittstelle zusammen [?] [?].
Traditionelle Expertensysteme beruhen meist auf regelbasierten Systemen mit „if-then“-Regeln, doch moderne Ansätze nutzen immer häufiger maschinelles Lernen, neuronale Netze oder hybride Systeme [?] [?].Moderne Systeme sind in der Lage, mit Unsicherheiten besser umzugehen und lernen teilweise neues Wissen hinzu („self-learning“), was bei klassischen Systemen nicht möglich war [?] [?].

2.3 Information Retrieval: Grundlagen & BM25-Algorithmus

Die Aufgabe der Information Retrieval (IR) besteht darin, aus umfangreichen Textsammlungen effizient relevante Informationen zu identifizieren. In klassischen IR-Systemen kommen häufig statistische Verfahren wie TF-IDF oder BM25 zum Einsatz, um die Relevanz von Dokumenten in Bezug auf eine Suchanfrage zu bewerten [?] [?].
Der BM25-Algorithmus ist ein probabilistisches Rankingverfahren, das die Termfrequenz (TF), die inverse Dokumentfrequenz (IDF) sowie die Dokumentlänge kombiniert, um eine Relevanzbewertung zu berechnen. Die BM25-Bewertungsfunktion ist wie folgt definiert:

$$\text{score}(D, Q) = \sum_{t \in Q} IDF(t) \cdot \frac{f(t, D) \cdot (k_1 + 1)}{f(t, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

Dabei bezeichnet:

- $f(t, D)$ die Häufigkeit des Terms t im Dokument D,
- $|D|$ die Länge des Dokuments,
- avgdl die durchschnittliche Dokumentlänge im Korpus,
- k_1 und b freie Parameter zur Steuerung der Gewichtung.

BM25 ist robust gegenüber Variationen in der Dokumentlänge und stellt bis heute einen etablierten Standard für lexikalische Suchverfahren dar [?].

2.4 Semantische Suche:Embeddings & Vektorraummodelle

Die semantische Suche geht über die traditionellen Methoden der Informationsretrieval hinaus, indem sie Embeddings verwendet – dichte Vektorrepräsentationen von Texten –, die semantische Ähnlichkeiten zwischen Wörtern oder Sätzen ermöglichen [?] [?]. Embeddings dieser Art werden von fortschrittlichen Modellen wie BERT oder Sentence Transformers erstellt; Suchanfragen und Dokumente werden als Vektoren im hochdimensionalen Raum verglichen („Vektorraummodell“) [?] [?].
Mit dieser Methode ist es möglich, relevante Inhalte zu finden, selbst wenn es sich um Synonymie oder Paraphrasierungen handelt – im Vergleich zu rein lexikalischen Verfahren wie BM25 ein Vorteil. Semantische Modelle sind jedoch rechenintensiv und erfordern spezialisierte Infrastrukturen, wie zum Beispiel Vektor-Datenbanken, um eine effiziente Suche zu ermöglichen [?].

2.5 Hybrid Search: Kombination von BM25 und Vektorsuche – Vorteile & Herausforderungen

Retrieval-Augmented Generation (RAG) kombiniert Large Language Models (LLMs) mit externem Information Retrieval. Bei jeder Anfrage werden zunächst relevante Dokumente aus einer Wissensbasis abgerufen („Retrieval“), anschließend als Kontext aufbereitet („Augmentation“) und schließlich zur Generierung einer Antwort verwendet („Generation“) [**?**, **?**, **?**].
Die RAG-Architektur besteht typischerweise aus einem Retriever-Modul (z. B. BM25, Embeddings oder hybride Verfahren), einem Augmentationsmodul zur Kontextaufbereitung sowie einem Generator-Modul in Form eines LLM.
Ein zentraler Bestandteil moderner Retrieval-Systeme ist die sogenannte Hybrid Search, bei der lexikalische Suchverfahren wie BM25 mit semantischen Vektorraumsuchen kombiniert werden. Während BM25 auf exakten Termübereinstimmungen basiert, ermöglicht die Vektorsuche die Identifikation semantisch ähnlicher Inhalte. Die kombinierte Bewertung kann beispielsweise als gewichtete Summe beider Verfahren formuliert werden:

$$\text{score}_{\text{hybrid}} = \alpha \cdot \text{score}_{\text{BM25}} + (1 - \alpha) \cdot \text{score}_{\text{vector}}$$

Der Vorteil dieses Ansatzes liegt in der komplementären Stärke beider Verfahren: Exakte Treffer werden durch BM25 zuverlässig erkannt, während die Vektorsuche auch bei abweichender Terminologie relevante Dokumente identifiziert. Dies führt zu einer verbesserten Abdeckung relevanter Inhalte und erhöht die Robustheit des Retrievals.
RAG adressiert zentrale Schwächen von LLMs wie Halluzinationen oder veraltetes Wissen durch faktisches Grounding an externen Datenquellen. Dies ist insbesondere für Expertensysteme mit hohen Anforderungen an Nachvollziehbarkeit und Aktualität von Bedeutung [**?**, **?**].
Herausforderungen bestehen weiterhin in der Qualität des Retrievals, der Integration heterogener Datenquellen sowie in Effizienz- und Kostenaspekten im Echtzeitbetrieb. Zudem können Halluzinationen trotz RAG auftreten, insbesondere wenn irrelevante oder fehlerhafte Kontexte abgerufen werden [**?**, **?**, **?**].

2.6 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) erweitert ein generatives Sprachmodell um einen externen Retrieval-Schritt. Statt ausschließlich auf parametrisches Wissen zu vertrauen, werden für eine Nutzeranfrage zunächst relevante Dokumentpassagen aus einer Wissensbasis abgerufen und anschließend als Kontext in den Prompt des LLM

eingebunden [**?**, **?**, **?**]. Die generierte Antwort basiert damit stärker auf überprüfbaren Quellen als bei einer rein promptbasierten Beantwortung.
Grundidee/Architektur: RAG koppelt einen Retriever mit einem Generator:

1. Query → Retrieval von relevanten Dokument-Chunks (BM25, Dense, Hybrid).
2. Top-k-Chunks werden dem LLM als Kontext übergeben.
3. LLM generiert Antwort, konditioniert auf Query + Belege.

RAG reduziert Halluzinationen und verbessert Faktentreue, macht Wissen leicht aktualisierbar, da nur der Index geändert werden muss.[**?**] [**?**] Für Expertensysteme ist RAG besonders relevant, weil domänenspezifische, dynamische Wissensbasen eingebunden und Entscheidungen transparent über Quellen belegt werden können.[**?**] [**?**]

3 Stand der Forschung zu LLMs in domänenspezifischen Expertensystemen mit Fokus auf RAG und Retrieval-Methoden

3.1 Aktuelle Ansätze mit LLMs in Expertensystemen

1. Domänenspezifische Anpassung: LLMs wie GPT-4, LLaMA oder spezialisierte Varianten (z.B. Lawyer LLaMA für Recht, Self-BioRAG für Medizin) werden zunehmend durch gezielte Integration von Fachwissen und Retrieval-Komponenten an spezifische Domänen angepasst. Dies geschieht meist durch Kombination von domänenspezifischem Training (z.B. Experten-Daten, Supervised Fine-Tuning) und Retrieval-Modulen, die relevante externe Wissensquellen einbinden [**?**] [**?**] [**?**] [**?**].

2. Retrieval-Augmented Generation (RAG): RAG ist der dominierende Ansatz, um Halluzinationen zu reduzieren, Aktualität zu gewährleisten und Quellenangaben zu ermöglichen. Hierbei wird das LLM mit einer externen Wissensbasis (Text, Knowledge Graph, Vektorstore) gekoppelt; relevante Dokumente werden zur Prompt ergänzt [**?**] [**?**] [**?**] [**?**] [**?**]. [**?**] [**?**].

3. Ontologien & Knowledge Graphs: Für komplexe Domänen werden zunehmend Ontologien und Knowledge Graphs als strukturierte Wissensquellen genutzt, um die Tiefe und Nachvollziehbarkeit der Antworten zu erhöhen [**?**] [**?**] [**?**] [**?**].

4. Praxisbeispiele: Erfolgreiche Anwendungen finden sich u.a. in Medizin (Self-BioRAG), Recht (Lawyer LLaMA), Bildung (E-Learning-RAG), Finanzen (Multi-Retriever-RAG) und Industrie [**?**] [**?**] [**?**]

3.2 Einsatz von RAG in der Praxis

1. Verbesserte Genauigkeit & Faktentreue: RAG-basierte Systeme zeigen signifikante Verbesserungen bei Genauigkeit, Faktentreue und Nachvollziehbarkeit gegenüber reinen LLMs – z.B.+7% bis +8% Rouge/Accuracy im medizinischen Bereich [**?**] [**?**] [**?**].

2. Domänenspezifische Evaluierung: In der Praxis werden verschiedene Metriken eingesetzt: Accuracy, Recall@k, nDCG@k, Halluzinationsrate sowie Expertenbewertungen [**?**] [**?**]. Beispiel: Im Gesundheitswesen wurde Mixtral 8×7B im RAG-Setting signifikant besser bewertet als Llama 3.1 70B [**?**]

3. Architekturvarianten: Neben klassischen Textretrievals kommen hybride Pipelines (BM25 + Dense Embeddings), graphbasierte RAG-Systeme sowie adaptive/hierarchische Retrievalstrategien zum Einsatz [?][?][?].

4. Praxisnahe Herausforderungen: Datenschutz (on-premise Deployment), Effizienz (Latenz/Kosten), Integration von Feedbackschleifen und multimodale Inputs sind wichtige Themenfelder [?].

3.3 Vergleich bestehender Retrieval-Methoden((BM25, Dense, Hybrid))

Methode	**Vorteile**	**Nachteile / Limitationen**	**Praxisrelevanz/ Ergebnisse**	**Quellen**
Sparse/BM25	Schnell, robust bei kleinen Korpora	Schwächen bei Synonymie/Semantik	Oft Baseline; manchmal besser als Dense	[?] [?] [?] [?]
Dense/Vektor	Semantische Suche möglich	Teurer im Indexing/Retrieval	Stärker bei komplexen Fragen	[?] [?] [?]
Hybrid	Kombiniert Stärken beider Ansätze	Komplexere Architektur	Beste Gesamtperformance; Recall@100 bis 0.997; Accuracy bis 83%	[?] [?] [?]
Cross-Encoding/Reranking	Höchste Präzision möglich	Sehr hohe Kosten/Latenz	Top-nDCG/Precision, aber teuer	[?]
Graph-basiert	Multihop Reasoning, Kontexttiefe	Aufbau/Integration aufwändig	Vorteil bei komplexen Domänenfragen	[?] [?]

Tabelle 3.1 Vergleich bestehender Retrieval-Methoden

Kernaussagen aus Studien:

1. Hybrid-Retrieval schlägt einzelne Methoden meist deutlich – z.B. +8% bis +20% Recall gegenüber Dense/Sparse allein; Cross-Encoding bringt weitere Präzisionsgewinne auf Kosten der Effizienz[?] [?].

2. In manchen Spezialfällen (Finanzen) kann BM25 sogar Dense Methods schlagen; Kontextabhängigkeit ist hoch [?].

3. Approximate Dense Retriever bieten Skalenvorteile bei großen Korpora mit minimalem Qualitätsverlust [?].

4. Adaptive Gewichtung zwischen Dense/Sparse je nach Query verbessert Performance weiter ("Dynamic Alpha Tuning“) [?].

3.4 Forschungslücken und Herausforderungen

Standardisierte Evaluation fehlt: Es gibt bislang keine einheitlichen Benchmarks oder Frameworks zur Bewertung von RAG-Systemen speziell für domänenspezifische Anwendungen – insbesondere fehlen standardisierte Metriken für Faktentreue/Halluzination und Nutzerakzeptanz [**?**] [**?**] [**?**].
Komplexe Reasoning-Aufgaben: Multihop-Retrieval und reasoning über mehrere Dokumente hinweg sind weiterhin eine Herausforderung – insbesondere für komplexe medizinische oder juristische Fragestellungen [**?**].
Dynamik Aktualität: Die kontinuierliche Aktualisierung externer Wissensbasen sowie die Integration neuer Datenquellen ist technisch wie organisatorisch ungelöst ("Knowledge Drift", Outdatedness) [**?**].
Explainability Transparenz: Die Nachvollziehbarkeit der Antwortentstehung bleibt trotz Quellenangabe oft limitiert; Erklärbarkeit ist ein aktives Forschungsfeld (K-hain-of-thought", Retrieval Path") [**?**]
Ethik Datenschutz: Ethische Aspekte sowie sichere Integration sensibler Daten sind unterrepräsentiert – besonders im Gesundheitswesen fehlen Leitlinien zur sicheren Nutzung von RAG-Systemen im Produktivbetrieb [**?**]

Fazit

In der Forschung geht der Trend bei Fachsystemen mit Sprachmodellen immer mehr zu flexiblen und kombinierten RAG-Ansätzen. Dass das technisch grundsätzlich funktioniert, ist inzwischen klar und es gibt auch erste Vergleichswerte. Trotzdem gibt es noch große Probleme, wenn es darum geht, die Ergebnisse objektiv zu bewerten, Entscheidungen verständlich zu machen und aktuelles Wissen dauerhaft einzubauen. Genau an diesen Punkten wird die Wissenschaft in den nächsten Jahren noch viel arbeiten müssen.

4 Anforderungsanalyse und Systemkonzeption

In diesem Kapitel werden die Anforderungen an das entwickelte Expertensystem für das Vergaberecht systematisch analysiert und in eine konkrete Systemkonzeption überführt. Ziel ist es, eine belastbare Grundlage für die spätere technische Implementierung zu schaffen. Dazu werden die Anforderungen zunächst aus fachlicher und technischer Perspektive beschrieben, anschließend mithilfe von User Stories konkretisiert und schließlich funktionalen Systemkomponenten zugeordnet.

4.1 Methodisches Vorgehen

Zur strukturierten Erhebung und Beschreibung der Anforderungen wird ein nutzerzentrierter Ansatz verfolgt. Die Modellierung erfolgt in Form von User Stories, da diese eine verständliche und zugleich praxisnahe Beschreibung funktionaler und technischer Anforderungen ermöglichen. Darüber hinaus unterstützen sie die systematische Ausrichtung der Entwicklung an den Bedürfnissen der späteren Nutzergruppen sowie an den Erfordernissen der technischen Umsetzung.
Ergänzend zu den User Stories werden Akzeptanzkriterien formuliert. Diese dienen dazu, die Anforderungen eindeutig, überprüfbar und validierbar zu machen. Das grundlegende Schema einer User Story lautet:

> Als <Rolle> möchte ich <Funktion>, damit <Nutzen>.

4.2 Fachliche Anforderungen

Das System soll Nutzer bei der Beantwortung vergaberechtlicher Fragestellungen unterstützen. Im Mittelpunkt steht die Verarbeitung natürlichsprachlicher Anfragen sowie die Generierung präziser, quellenbasierter und nachvollziehbarer Antworten. Da das System in einem juristisch sensiblen Anwendungsfeld eingesetzt wird, ist insbesondere sicherzustellen, dass generierte Inhalte ausschließlich auf den zugrunde liegenden Dokumenten basieren.
Die Antworten dürfen keine nicht belegbaren Aussagen enthalten. Stattdessen soll das System nur solche Informationen ausgeben, die durch die bereitgestellten Rechtsquellen, beispielsweise UVgO oder VgV, gestützt werden. Darüber hinaus soll das System auch unscharf formulierte, unvollständige oder semantisch variierende Anfragen sinnvoll verarbeiten können.
Ein weiteres fachliches Ziel besteht in der transparenten Darstellung der verwendeten Quellen. Dadurch soll die Nachvollziehbarkeit der Antwortgenerierung erhöht und den Nutzern eine eigenständige Überprüfung der ausgegebenen Inhalte ermöglicht werden.

4.3 Technische Anforderungen

Das System soll Nutzer bei der Beantwortung vergaberechtlicher Fragestellungen unterstützen. Im Mittelpunkt steht die Verarbeitung natürlichsprachlicher Anfragen sowie die Generierung präziser, quellenbasierter und nachvollziehbarer Antworten. Da das System in einem juristisch sensiblen Anwendungsfeld eingesetzt wird, ist insbesondere sicherzustellen, dass generierte Inhalte ausschließlich auf den zugrunde liegenden Dokumenten basieren.
Die Antworten dürfen keine nicht belegbaren Aussagen enthalten. Stattdessen soll das System nur solche Informationen ausgeben, die durch die bereitgestellten Rechtsquellen, beispielsweise UVgO oder VgV, gestützt werden. Darüber hinaus soll das System auch unscharf formulierte, unvollständige oder semantisch variierende Anfragen sinnvoll verarbeiten können.
Ein weiteres fachliches Ziel besteht in der transparenten Darstellung der verwendeten Quellen. Dadurch soll die Nachvollziehbarkeit der Antwortgenerierung erhöht und den Nutzern eine eigenständige Überprüfung der ausgegebenen Inhalte ermöglicht werden. 4.3 Technische Anforderungen
Aus den fachlichen Anforderungen ergeben sich mehrere technische Anforderungen an Architektur und Betrieb des Systems. Zunächst ist ein modularer Systemaufbau erforderlich, sodass einzelne Komponenten unabhängig voneinander entwickelt, betrieben, gewartet und erweitert werden können. Dies betrifft insbesondere die Trennung von Benutzeroberfläche, Anwendungslogik, Retrieval-Komponente, Sprachmodell-Anbindung und Datenhaltung.
Darüber hinaus muss eine performante Verarbeitung und Suche innerhalb der zugrunde liegenden Dokumente gewährleistet sein, um kurze Antwortzeiten zu ermöglichen. Ebenso ist die Architektur so auszugestalten, dass neue Dokumente ohne grundlegende Änderungen an der Systemstruktur integriert, verarbeitet und indexiert werden können.
Ein weiterer technischer Schwerpunkt liegt in der Qualitätssicherung der generierten Antworten. Insbesondere müssen Mechanismen vorgesehen werden, die Halluzinationen reduzieren und die Antworttreue gegenüber den zugrunde liegenden Quellen absichern.

4.4 Definition der User Stories

Basierend auf den identifizierten Anforderungen werden im Folgenden zentrale User Stories definiert. Diese konkretisieren die funktionalen Anforderungen aus Sicht der Nutzer und Entwickler und bilden die Grundlage für die spätere Ableitung der Systemarchitektur.

US-01: Frage-Antwort-Zyklus (Kernfunktionalität)

Als Nutzer möchte ich eine fachliche Frage in natürlicher Sprache stellen und eine präzise, quellenbasierte Antwort erhalten, damit ich relevante Informationen schnell und ohne manuelle Recherche in umfangreichen Dokumenten finde.
Akzeptanzkriterien:

- Das System verarbeitet natürlichsprachliche Eingaben. Antwort wird innerhalb einer angemessenen Zeitspanne bereitgestellt.
- Die Antwort basiert ausschließlich auf den bereitgestellten Dokumenten.
- Falls keine relevanten Informationen gefunden werden, gibt das System eine entsprechende Rückmeldung aus
- Die Antwort wird im Chat-Verlauf angezeigt

US-02: Hybride Informationssuche

Als Nutzer möchte ich, dass sowohl exakte Begriffstreffer als auch semantisch ähnliche Inhalte berücksichtigt werden, damit relevante Informationen unabhängig von der konkreten Formulierung meiner Anfrage gefunden werden.
Akzeptanzkriterien:

- Das System nutzt mehrere Suchstrategien zur Informationsgewinnung
- Sowohl lexikalische als auch semantische Ähnlichkeiten werden berücksichtigt
- Die Suchergebnisse werden zu einer gemeinsamen Rangliste zusammengeführt
- Die Anzahl der berücksichtigten Treffer ist konfigurierbar

US-03: Intent-basierte Antwortgenerierung

Als Nutzer möchte ich, dass das System die Absicht meiner Anfrage erkennt und die Antwort entsprechend ausrichtet, damit ich eine präzise und kontextgerechte Antwort erhalte.
Akzeptanzkriterien:

- Das System erkennt unterschiedliche Arten von Anfragen
- Die erkannte Absicht beeinflusst die Generierung der Antwort
- Für unterschiedliche Anfragearten werden angepasste Antwortstrategien verwendet

US-04: Sicherstellung der Antworttreue (Halluzinationsvermeidung)

Als Nutzer möchte ich sicher sein können, dass die generierten Antworten ausschließlich auf den bereitgestellten Quellen basieren, damit keine inhaltlich falschen oder unbelegten Aussagen entstehen.
Akzeptanzkriterien:

- Die generierte Antwort wird auf Übereinstimmung mit den zugrunde liegenden Dokumenten geprüft
- Bei fehlender Übereinstimmung wird keine inhaltliche Antwort ausgegeben
- Stattdessen erfolgt eine standardisierte Rückmeldung

US-05: Dokumentenverarbeitung und Indexierung

Als Entwickler möchte ich Dokumente automatisiert verarbeiten und indexieren können, damit die Wissensbasis des Systems flexibel erweitert werden kann.
Akzeptanzkriterien:

- Dokumente werden automatisiert eingelesen und strukturiert verarbeitet
- Inhalte werden für die Suche geeignet gespeichert
- Neue Dokumente können ohne Anpassung der Architektur integriert werden
- Der Prozess ist reproduzierbar ausführbar

US-06: Bewertung der Antwortqualität

Als Entwickler möchte ich die Qualität der generierten Antworten systematisch bewerten können, damit die Leistungsfähigkeit des Systems objektiv analysiert werden kann.
Akzeptanzkriterien:

- Antworten werden anhand definierter Kriterien bewertet
- Die Bewertung erfolgt automatisiert
- Ergebnisse werden strukturiert gespeichert
- Die Bewertungslogik ist anpassbar

US-07: Benutzeroberfläche und Interaktion

Als Nutzer möchte ich eine intuitive Benutzeroberfläche verwenden können, damit ich effizient mit dem System interagieren kann.
Akzeptanzkriterien:

- Eine Chat-basierte Oberfläche ist verfügbar
- Eingaben und Antworten werden übersichtlich dargestellt
- Der Verlauf ist einsehbar
- Verschiedene Betriebsmodi sind auswählbar

US-08: Datenexport für Analysezwecke

Als Entwickler möchte ich Interaktionsdaten exportieren können, damit diese für Evaluationen genutzt werden können.
Akzeptanzkriterien:

- Relevante Daten werden strukturiert erfasst
- Ein Export in standardisiertem Format ist möglich
- Alle notwendigen Informationen sind enthalten
- Der Export kann durch den Nutzer ausgelöst werden

4.5 Ableitung der Systemanforderungen

Aus den definierten User Stories lassen sich konkrete funktionale Anforderungen sowie deren Zuordnung zu den Systemkomponenten ableiten.

User Story	Anforderung	Systemkomponente
US-01	Verarbeitung von Anfragen und Antwortgenerierung	Backend (FastAPI)
US-02	Kombination mehrerer Suchverfahren	Retrieval (Elasticsearch)
US-03	Erkennung der Nutzerintention	Intent-Modul
US-04	Prüfung der Antworttreue	Qualitätssicherung
US-05	Dokumentenverarbeitung und Indexierung	Indexierungsmodul
US-06	Automatisierte Bewertung	Evaluationsmodul
US-07	Benutzeroberfläche	Frontend (Streamlit)
US-08	Export von Daten	Exportmodul

Tabelle 4.1 Zusammenhang zwischen User Stories und Systemkomponenten

4.6 Systemarchitektur

Auf Basis der zuvor definierten Anforderungen wird im Folgenden die Systemarchitektur des entwickelten Expertensystems beschrieben.
Das System folgt einer modularen, serviceorientierten Architektur. Die einzelnen Komponenten sind klar voneinander getrennt und kommunizieren über definierte Schnittstellen.
Die Benutzerinteraktion erfolgt über eine mit Streamlit realisierte Oberfläche. Diese ermöglicht die Eingabe natürlichsprachlicher Anfragen sowie die Darstellung der generierten Antworten einschließlich der zugrunde liegenden Quellen.
Das Backend, implementiert mit FastAPI, übernimmt die zentrale Steuerung des Systems. Es verarbeitet eingehende Anfragen, koordiniert die Retrieval-Komponente, bindet das Sprachmodell ein und stellt die Antwortgenerierung sicher.
Die Retrieval-Komponente basiert auf Elasticsearch und kombiniert klassische Volltextsuche (BM25) mit semantischer Vektorsuche. Dadurch wird sowohl eine exakte als auch eine kontextbasierte Informationssuche ermöglicht.
Zur Generierung der Antworten wird ein lokal betriebenes Sprachmodell über Ollama eingesetzt. Dieses verarbeitet den durch das Retrieval bereitgestellten Kontext und erzeugt eine natürlichsprachliche Antwort.
Ein zusätzlicher Validierungsschritt dient der Qualitätssicherung. Dabei wird überprüft, ob die generierte Antwort vollständig durch die zugrunde liegenden Dokumente gedeckt ist. Dies trägt maßgeblich zur Vermeidung von Halluzinationen bei.
Die Dokumentenverarbeitung erfolgt automatisiert. Eingehende Dokumente werden in Textsegmente zerlegt, aufbereitet und sowohl lexikalisch als auch semantisch indexiert.
Die Bereitstellung und Orchestrierung der Systemkomponenten erfolgt containerbasiert mittels Docker Compose. Dies ermöglicht eine einfache Installation, Wartung und Erweiterung des Systems.

4.7 Zusammenfassung

In diesem Kapitel wurden die fachlichen und technischen Anforderungen an das System strukturiert erfasst und in Form von User Stories konkretisiert. Darauf aufbauend wurden funktionale Anforderungen abgeleitet und eine modulare Systemarchitektur entworfen.
Die beschriebenen Konzepte bilden die Grundlage für die im folgenden Kapitel dargestellte Implementierung des Systems.

5 Implementierung

Ziel dieses Kapitels ist die detaillierte Darstellung der technischen Umsetzung des entwickelten Retrieval-Augmented-Generation-(RAG)-Systems. Der Fokus liegt auf der Verarbeitung der Dokumente, der hybriden Suchstrategie sowie der Realisierung der einzelnen Systemkomponenten.
Das System verfolgt das Ziel, nutzerspezifische Anfragen im Kontext von Vergabedokumenten präzise und kontextbasierte Antworten zu erzeugen. Hierzu werden relevante Dokumentinhalte identifiziert, aufbereitet und als Grundlage für die Generierung der Antworten verwendet.

5.1 Datenaufbereitung und Chunking

Die Grundlage des Systems bilden Dokumente im PDF-Format, deren Inhalte zunächst extrahiert und anschließend in kleinere Textsegmente (Chunks) unterteilt werden. Dieser Schritt ist erforderlich, um eine effiziente Indexierung sowie eine präzise semantische Suche zu ermöglichen.
Die Zerlegung erfolgt anhand einer festen Chunk-Größe mit zusätzlicher Überlappung. Die Überlappung stellt sicher, dass relevante Informationen an Segmentgrenzen nicht verloren gehen und der semantische Zusammenhang erhalten bleibt.
Die Wahl der Chunk-Größe stellt einen Kompromiss zwischen Kontexttiefe und Retrieval-Effizienz dar. Während zu große Segmente zu unscharfen Treffern führen können, besteht bei zu kleinen Segmenten die Gefahr eines Verlusts semantischer Zusammenhänge.

Listing 1 Chunking-Verfahren

```
def chunk_text(text: str, chunk_size: int = CHUNK_SIZE, overlap: int =
    chunks = []
    for i in range(0, len(text), chunk_size - overlap):
        chunk = text[i:i + chunk_size]
        if chunk.strip():
            chunks.append(chunk)
    return chunks
```

Die Extraktion der Inhalte erfolgt seitenweise aus den PDF-Dokumenten:

Listing 2 PDF-Text-Extraktion

```
reader = PdfReader(io.BytesIO(content_bytes))
for page in reader.pages:
    text += page.extract_text() or ""
```

Die erzeugten Textsegmente bilden die Grundlage für die nachfolgende Indexierung sowie die spätere Informationssuche.

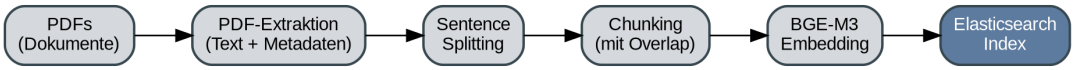


Abb. 5.1 Verarbeitung von PDF-Dokumenten zu Text-Chunks

5.2 Hybride Suche

Die Informationssuche basiert auf einer hybriden Strategie, die klassische lexikalische Suche (BM25) mit semantischer Vektorsuche kombiniert. Während BM25 insbesondere exakte Wortübereinstimmungen berücksichtigt, ermöglicht die Vektorsuche das Auffinden semantisch ähnlicher Inhalte.
Zur Reduktion der Latenz werden beide Suchverfahren parallel ausgeführt:

Listing 3 Parallele Hybrid-Suche

```
def search_hybrid(query: str, intent: str):
    with ThreadPoolExecutor(max_workers=2) as pool:
        future_bm25 = pool.submit(search_bm25, query, intent, 15)
        future_emb = pool.submit(get_embedding, query)

query_embedding = future_emb.result()
bm25_hits = future_bm25.result()

vector_hits = search_vector(query_embedding, size=15)

final_hits, max_score = reciprocal_rank_fusion(bm25_hits, vector_hits)
return final_hits, max_score
```

Die Zusammenführung der Ergebnisse erfolgt mittels Reciprocal Rank Fusion (RRF). Dieses Verfahren kombiniert die Ranglisten beider Suchmethoden und ermöglicht eine robuste, skalierungsunabhängige Bewertung der Gesamtrelevanz.

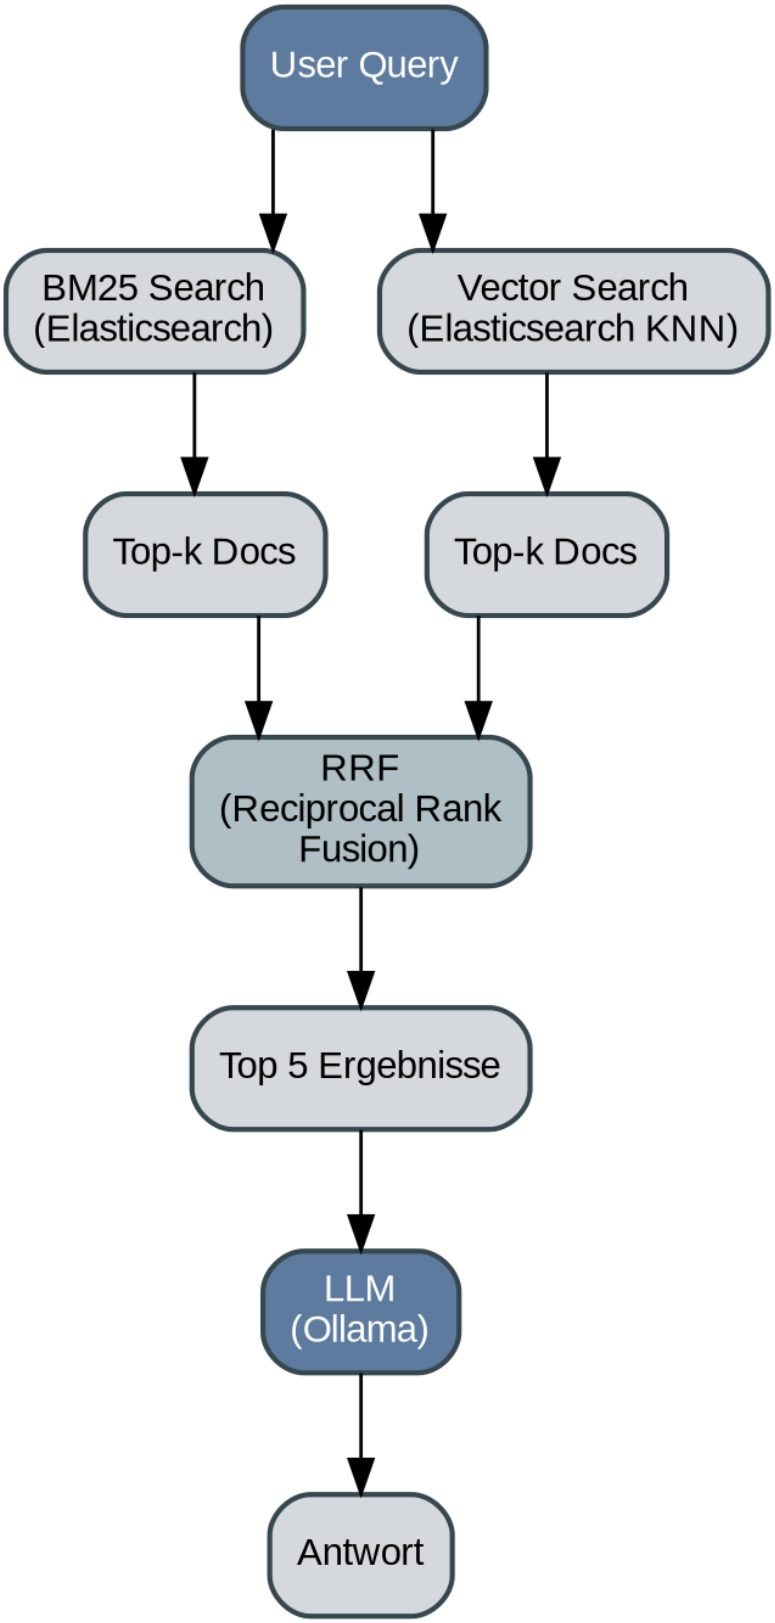


Abb. 5.2 Ablauf der hybriden Suche mit BM25, Vektorsuche und RRF

5.3 Backend-Architektur mit FastAPI

Das Backend wurde mit dem Framework FastAPI realisiert und fungiert als zentrale Orchestrierungsschicht des Systems. Es übernimmt die Verarbeitung eingehender Anfragen und koordiniert die Kommunikation zwischen den einzelnen Komponenten. Dabei verbindet das Backend die Retrieval-Komponente (Elasticsearch), das Sprachmodell (über Ollama) sowie das Frontend.

Listing 4 FastAPI Initialisierung

```
app = FastAPI(
    title="RAG API – Bachelor Arbeit",
    version="1.0.0"
)

app.include_router(query_router, prefix="/api")
```

Zur Überprüfung der Systemverfügbarkeit wurde ein Health-Endpunkt implementiert:

Listing 5 Health Endpoint

```
@app.get("/health")
async def health():
    return {"status": "healthy"}
```

Der Endpunkt `/api/ask` stellt die zentrale Schnittstelle dar und bildet den vollständigen RAG-Prozess ab.

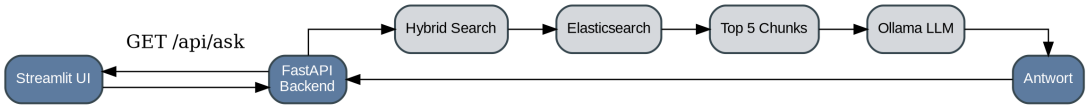


Abb. 5.3 Ablauf einer Anfrage durch das Backend

5.4 LLM-Integration und Prompting

Die Generierung der Antworten erfolgt durch ein lokal betriebenes Large Language Model über die Ollama-Schnittstelle. Das Modell erhält sowohl die Nutzeranfrage als auch den zuvor ermittelten Kontext als Eingabe.
Das Sprachmodell verfügt über keinen direkten Zugriff auf externe Wissensquellen, sondern basiert ausschließlich auf dem bereitgestellten Kontext (Closed-Book-Ansatz).
Der Prompt wird dynamisch aufgebaut, um sicherzustellen, dass die Antwort ausschließlich auf den bereitgestellten Informationen basiert:

Listing 6 Prompt-Erstellung

```
def build_prompt(query: str, context: str, intent: str, model: str) ->
    return f"""
KONTEXT:
{context}

FRAGE: {query}

Basiere deine Antwort nur auf dem Kontext.
"""
```

Diese Struktur trägt maßgeblich zur Reduktion von Halluzinationen bei und erhöht die Nachvollziehbarkeit der generierten Antworten.

5.5 Antwortvalidierung

Zur weiteren Verbesserung der Antwortqualität wurde ein zusätzlicher Validierungsschritt implementiert. Dabei wird überprüft, ob die generierte Antwort durch den bereitgestellten Kontext gestützt ist.
Die Validierung erfolgt durch eine modellbasierte Klassifikation der Antwort hinsichtlich ihrer Übereinstimmung mit dem Kontext.

Listing 7 Faithfulness Check

```
def check_faithfulness(query: str, context: str, answer: str, model: st
    if "JA" in verdict:
        return answer
    return FALLBACK_ANSWER
```

Falls die Antwort nicht ausreichend gestützt ist, wird eine alternative Antwort ausgegeben. Dieser Mechanismus reduziert das Risiko halluzinierter Inhalte.

5.6 Frontend-Implementierung mit Streamlit

Für die Benutzerinteraktion wurde ein webbasiertes Frontend mit Streamlit realisiert. Dieses ermöglicht die Eingabe natürlichsprachlicher Anfragen sowie die Darstellung der generierten Antworten in Form eines Chat-Interfaces.
Das Frontend dient ausschließlich der Interaktion und enthält keine Geschäftslogik, wodurch eine klare Trennung zwischen Präsentations- und Verarbeitungsschicht gewährleistet wird.

Listing 8 Chat-Eingabe im Frontend

```
user_query = st.chat_input("Stellen Sie Ihre Frage")
```

```
if user_query:
    data = call_ask_api(user_query, selected_model)
```

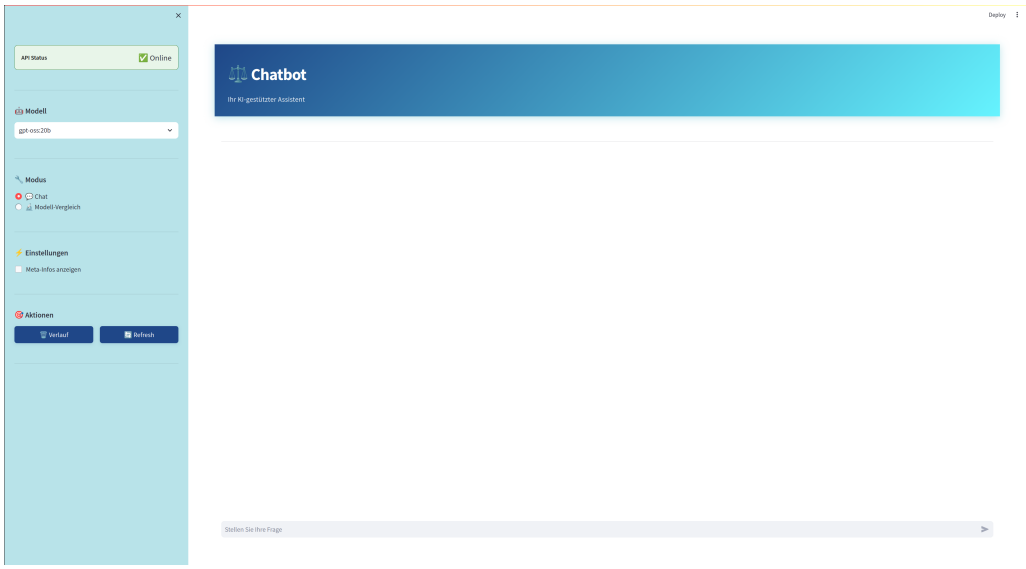


Abb. 5.4 Benutzeroberfläche des Systems

5.7 Konfiguration

Zentrale Systemparameter werden in einer Konfigurationsdatei definiert, um eine flexible Anpassung des Systems zu ermöglichen:

Listing 9 Systemparameter

```
CHUNK_SIZE = 1000
HYBRID_BM25_W = 0.4
HYBRID_VECTOR_W = 0.6
```

Diese Parameter beeinflussen maßgeblich die Qualität der Suche sowie die Performance des Systems.

5.8 Zusammenfassung

Die Implementierung integriert Datenaufbereitung, hybride Suche, Backend-Architektur, Sprachmodellintegration sowie ein interaktives Frontend zu einem leistungsfähigen Gesamtsystem.
Die gewählte Architektur stellt einen Kompromiss zwischen Antwortqualität, Systemlatenz und Komplexität dar. Insbesondere die Kombination aus hybrider Suche und nachgelagerter Validierung trägt wesentlich zur Verbesserung der Ergebnisqualität bei und ermöglicht eine robuste, nachvollziehbare Verarbeitung natürlichsprachlicher Anfragen im Vergabekontext.

6 Evaluation

Ziel dieses Kapitels ist die systematische Bewertung des entwickelten Chatbots zur Unterstützung bei vergaberechtlichen Fragestellungen. Die Evaluation erfolgt auf zwei Ebenen: der Qualität der Dokumentenretrieval-Komponente sowie der Qualität der generierten Antworten. Hierfür werden sowohl klassische Information-Retrieval-Metriken als auch ein LLM-as-a-Judge-Ansatz eingesetzt.

6.1 Evaluationsmethodik

6.2 Evaluationsmethodik

Die Evaluation basiert auf einem Datensatz realistischer Nutzeranfragen einschließlich der zugehörigen Referenzantworten sowie relevanter Ground-Truth-Dokumente. Ziel ist es, die Leistungsfähigkeit des entwickelten Retrieval-Augmented-Generation-(RAG)-Systems sowohl hinsichtlich der Dokumentensuche als auch der Antwortgenerierung systematisch zu bewerten.
Der Evaluationsaufbau orientiert sich an einem strukturierten Benchmark-Ansatz, um reproduzierbare und vergleichbare Ergebnisse zu gewährleisten. Hierzu werden die Anfragen in zwei Kategorien unterteilt: (i) domänenspezifische, kontextbezogene Fragen aus dem Bereich des Vergaberechts sowie (ii) domänenfremde, kontextunabhängige Fragen. Diese Trennung ermöglicht eine differenzierte Analyse der fachlichen Antwortqualität sowie der Robustheit des Systems gegenüber irrelevanten oder außerhalb der Wissensbasis liegenden Eingaben.
Für jede Anfrage werden im Rahmen der Evaluation die folgenden Komponenten systematisch erfasst und gespeichert:

- die ursprüngliche Nutzeranfrage,
- die durch das Retrieval-Modul identifizierten Dokumente,
- die generierte Antwort des Sprachmodells,
- sowie Referenzantworten bzw. relevante Ground-Truth-Dokumente.

Die Verarbeitung und Speicherung der Ergebnisse erfolgt in strukturierten JSON-Dateien. Dies ermöglicht eine automatisierte Auswertung sowie eine vollständige Nachvollziehbarkeit und Reproduzierbarkeit der Experimente.
Zur Bewertung des Systems kommen zwei komplementäre Ansätze zum Einsatz. Einerseits wird die Qualität des Retrievals mithilfe klassischer Information-Retrieval-Metriken wie Precision@k und Recall@k gemessen. Andererseits wird die Qualität der generierten Antworten durch einen LLM-as-a-Judge-Ansatz bewertet.

Die Antwortgenerierung erfolgt durch das Sprachmodell *gpt-oss* (20B). Die Bewertung der generierten Antworten wird durch ein separates Sprachmodell (*mistral:latest*) durchgeführt. Durch diese Trennung von Generierung und Bewertung wird eine methodisch fundierte und vergleichsweise objektive Einschätzung der Antwortqualität ermöglicht.
Der Datensatz umfasst unter anderem folgende Anfragen:
Fragen im Kontext:

1. Ab welchem Betrag ist eine Vergabe durchzuführen (UVgO, VV ÖA, LHO)?
2. Ab welchem Betrag ist eine Beschaffung durchzuführen (UVgO, VV ÖA, LHO)?
3. Wie lange dauert ein Vergabeverfahren (UVgO, VgV)?
4. Ist der Höchstbetrag in Brutto oder Netto anzugeben (UVgO, VgV, VV ÖA)?
5. Warum ist ein Vergabeverfahren durchzuführen (LHO, UVgO, VgV, VV ÖA)?
6. Welcher Preis ist zu beachten (VV ÖA)?
7. Als Mitarbeitender oder Professor*in möchte ich wissen, ob Beträge, Preise und Kostenschätzungen in Brutto oder Netto anzugeben sind, um das korrekte Verfahren bestimmen zu können.
8. Als Institutssekretariat möchte ich wissen, welche Dokumente der Beschaffungsstelle vorgelegt werden müssen, um eine Bestellung rechtssicher einzuleiten.
9. Als wissenschaftlich Mitarbeitender möchte ich wissen, wie lange eine Ausschreibung offen sein muss und welche Fristen für Angebotsabgabe und Zuschlag gelten.
10. Als wissenschaftlich Mitarbeitende möchte ich erfahren, ob Angebote selbst eingeholt werden dürfen oder ob dies durch die Beschaffungsstelle erfolgt.
11. Als Projektleiter*in oder Mitarbeitender möchte ich verstehen, was ein Vergabeverfahren bzw. eine Beschaffung im Kontext der Vergaberegelungen bedeutet.
12. Als Projektleiter*in einer rheinland-pfälzischen Hochschule möchte ich wissen, warum Vergabeverfahren durchgeführt werden müssen und warum eine direkte Vergabe an einen Wunschlieferanten nicht zulässig ist.

Fragen außerhalb des Kontexts:

1. Wie mache ich eine Mondlandung?
2. Wie koche ich Pasta?
3. Wer hat die Relativitätstheorie erfunden?
4. Wie repariere ich einen kaputten Laptop?
5. Ich brauche einen Laptop - wie beschaffe ich diesen?

Durch die Kombination aus Retrieval-Evaluation und LLM-basierter Antwortbewertung wird ein ganzheitliches Benchmarking des Systems entlang der gesamten RAG-Pipeline ermöglicht. Dies erlaubt sowohl die isolierte Analyse einzelner Komponenten als auch die Untersuchung ihrer Wechselwirkungen innerhalb der Gesamtarchitektur.

6.3 Retrieval-Evaluation

Zur Bewertung der Suchqualität werden die Metriken Precision@k und Recall@k herangezogen. Diese quantifizieren den Anteil relevanter Dokumente innerhalb der Top- k -Ergebnisse sowie die Abdeckung aller relevanten Dokumente.
Die Berechnung erfolgt gemäß:

- Precision@k = relevante Treffer in Top- k / k
- Recall@k = relevante Treffer in Top- k / Gesamtanzahl relevanter Treffer

Die Ergebnisse zeigen ein differenziertes Bild der Retrieval-Leistung: Bei kleinen k -Werten werden relevante Dokumente nicht zuverlässig auf den obersten Rängen platziert, was sich in einer Precision@1 von 0,00 widerspiegelt. Mit zunehmendem k verbessert sich die Retrieval-Qualität jedoch deutlich.
Insbesondere erreicht das System bei k=5 einen Recall von 1,0, sodass sämtliche relevanten Dokumente innerhalb der Top-5-Ergebnisse enthalten sind. Gleichzeitig liegt die Precision@5 bei 0,60, was auf das Vorhandensein nicht relevanter Dokumente in den Top-Ergebnissen hinweist.

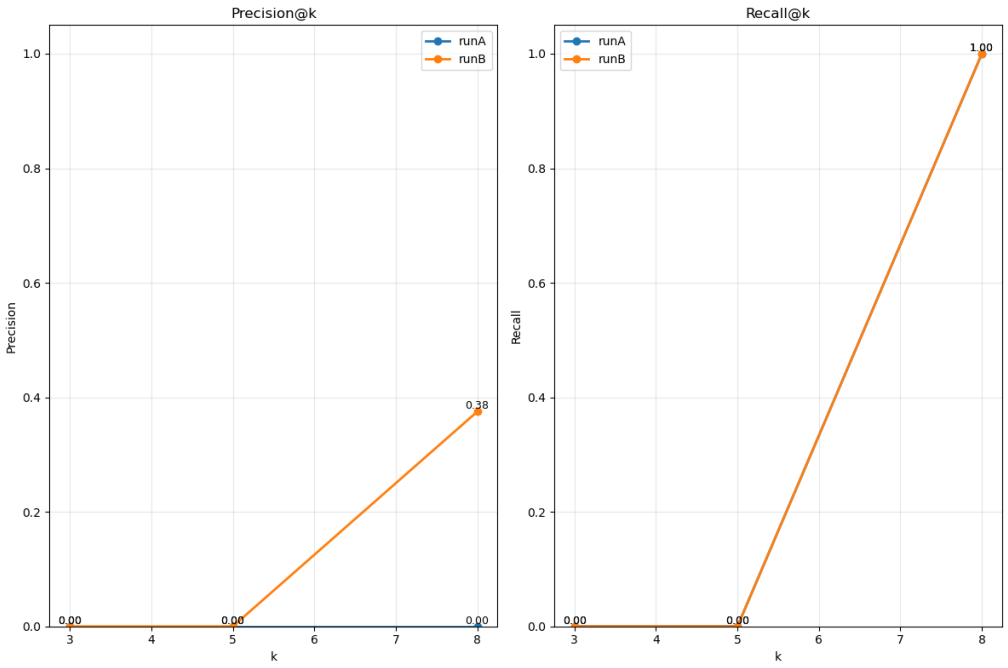


Abb. 6.1 Precision@k und Recall@k für verschiedene Werte von k

6.3.1 Analyse der Hybrid-Suche

Die Analyse des Überlappungsgrades zwischen BM25 und Vektorsuche zeigt eine vergleichsweise geringe Überschneidung der identifizierten Dokumente.

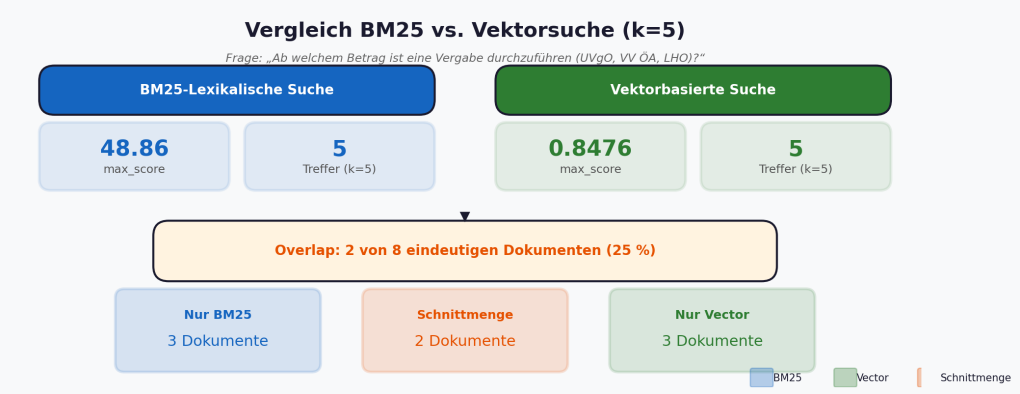


Abb. 6.2 Vergleich der Retrieval-Ergebnisse von BM25 und Vektorsuche für k=5

Wie in Abbildung 6.2 dargestellt, liefern beide Verfahren jeweils fünf Treffer, von denen sich lediglich zwei Dokumente überschneiden (40,
Diese Ergebnisse verdeutlichen die komplementären Eigenschaften der Ansätze: Während BM25 primär auf lexikalische Übereinstimmungen reagiert, erfasst die Vektorsuche semantische Zusammenhänge. Die vergleichsweise geringe Schnittmenge liefert somit eine empirische Begründung für den Einsatz einer hybriden Suchstrategie.
Die Kombination beider Verfahren führt zu einer verbesserten Abdeckung relevanter Dokumente und stellt einen zentralen Faktor für die insgesamt hohe Retrieval-Qualität dar.

6.4 Ergebnisse der Antwortbewertung

Zur Bewertung der generierten Antworten wird ein LLM-as-a-Judge-Ansatz eingesetzt. Die Antworten werden durch das Modell *gpt-oss* (20B) generiert und anschließend durch *mistral:latest* bewertet.
Die Bewertung erfolgt anhand der folgenden Kriterien:

- Correctness (fachliche Korrektheit)
- Completeness (inhaltliche Vollständigkeit)
- Faithfulness (Quellentreue)
- Clarity (Verständlichkeit und Struktur)

Die aggregierten Ergebnisse zeigen ein insgesamt sehr hohes Qualitätsniveau:

- Correctness: 5,00
- Completeness: 4,67
- Faithfulness: 5,00
- Clarity: 5,00

Dies entspricht einer Gesamtbewertung von 4,92 von 5,0 Punkten. Die aggregierten Ergebnisse sind in Abbildung 6.3 dargestellt.

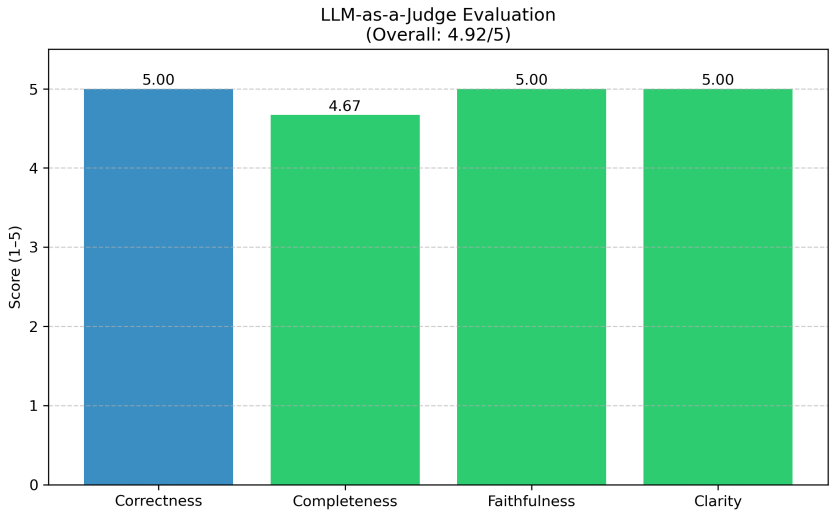


Abb. 6.3 Bewertung der Antwortqualität durch ein LLM (Skala 1–5)

Die Ergebnisse zeigen, dass die generierten Antworten fachlich korrekt, klar strukturiert und eng an den zugrunde liegenden Quellen orientiert sind. Dies ist insbesondere im juristischen Kontext von zentraler Bedeutung.
Die leicht reduzierte Bewertung der Completeness deutet darauf hin, dass bei komplexeren Fragestellungen nicht alle relevanten Aspekte vollständig abgedeckt werden.

6.4.1 Qualitative Analyse

Die qualitative Analyse zeigt zwei zentrale Verhaltensweisen des Systems.
Zum einen erkennt das System zuverlässig Situationen, in denen die bereitgestellten Kontextinformationen nicht ausreichen, und kommuniziert diese Unsicherheit explizit. Dieses Verhalten trägt wesentlich zur Reduktion von Halluzinationen bei.
Zum anderen werden in Einzelfällen zusätzliche Informationen generiert, die nicht vollständig durch die zugrunde liegenden Quellen abgesichert sind. Dies verdeutlicht die inhärenten Grenzen des Systems im Umgang mit unvollständigem Kontext.

6.5 Diskussion

Die Kombination aus Retrieval-Metriken und LLM-basierter Bewertung ermöglicht eine differenzierte Analyse der Systemleistung.
Während Precision@k und Recall@k die Effektivität der Dokumentensuche quantifizieren, bewertet der LLM-as-a-Judge-Ansatz die tatsächliche Nutzbarkeit der generierten Antworten.
Die Ergebnisse zeigen, dass die hybride Suche einen signifikanten Beitrag zur Retrieval-Qualität leistet, indem sie die jeweiligen Stärken von BM25 und Vektorsuche kombiniert. Gleichzeitig wird deutlich, dass die Qualität der generierten Antworten maßgeblich von der Qualität der zugrunde liegenden Retrieval-Ergebnisse abhängt.
Die beobachteten Einschränkungen in der Vollständigkeit sind daher weniger auf das Sprachmodell selbst als vielmehr auf die strukturellen Eigenschaften von Retrieval-Augmented-Generation-Systemen zurückzuführen.

6.6 Zusammenfassung

Zusammenfassend zeigt die Evaluation, dass das entwickelte System die definierten Anforderungen in hohem Maße erfüllt.
Die Hybrid-Suche ermöglicht eine zuverlässige Identifikation relevanter Dokumente und erreicht bei k=5 einen vollständigen Recall. Die generierten Antworten weisen mit einem Gesamtwert von 4,92/5,0 eine hohe fachliche Qualität sowie eine ausgeprägte Quellentreue auf.
Der eingesetzte Mechanismus zur Sicherstellung der Quellentreue trägt effektiv zur Reduktion von Halluzinationen bei und erhöht die Verlässlichkeit der Systemausgaben.
Einschränkend ist anzumerken, dass der Evaluationsdatensatz mit drei Testfragen nur eine begrenzte Aussagekraft besitzt. Eine Erweiterung des Datensatzes sowie die Einbeziehung menschlicher Evaluationen stellen sinnvolle Ansätze für zukünftige Arbeiten dar.
Insgesamt belegen die Ergebnisse, dass die Kombination aus Hybrid-Retrieval und LLM-basierter Antwortgenerierung eine tragfähige Grundlage für ein domänenspezifisches Expertensystem im vergaberechtlichen Kontext darstellt.

7 Diskussion

7.1 Bewertung der Ergebnisse

Die im Rahmen der Evaluation erzielten Ergebnisse bestätigen die grundsätzliche Leistungsfähigkeit des entwickelten Retrieval-Augmented-Generation-(RAG)-Systems. Sowohl die Retrieval-Komponente als auch die Qualität der generierten Antworten erreichen ein überzeugendes Niveau und sind für den Einsatz im juristischen Kontext geeignet.

Im Einklang mit dem Stand der Forschung zeigt sich, dass insbesondere hybride Retrieval-Ansätze einen signifikanten Mehrwert bieten. Die Kombination aus BM25 und Vektorsuche führt zu einer verbesserten Abdeckung relevanter Dokumente, da sowohl lexikalische als auch semantische Ähnlichkeiten berücksichtigt werden. Die Ergebnisse der Evaluation bestätigen somit die in der Literatur beschriebenen Vorteile hybrider Suchverfahren.

Die Analyse der Antwortqualität verdeutlicht, dass die Leistungsfähigkeit des Systems maßgeblich durch die Qualität der bereitgestellten Kontexte bestimmt wird. Unterschiede zwischen den eingesetzten Sprachmodellen zeigen sich primär in der sprachlichen Ausgestaltung der Antworten, während die inhaltliche Qualität weitgehend vergleichbar bleibt. Dies unterstreicht die zentrale Rolle des Retrievals innerhalb von RAG-Systemen.

Einschränkend ist zu berücksichtigen, dass die Evaluation auf einem vergleichsweise kleinen Datensatz basiert. Die Ergebnisse sind daher als indikativ zu verstehen und erlauben keine umfassende statistische Verallgemeinerung.

7.2 Stärken und Schwächen des Systems

Eine zentrale Stärke des Systems liegt in der effektiven Kombination von Retrieval und Generierung. Die hybride Suchstrategie ermöglicht eine robuste Identifikation relevanter Dokumente und bildet die Grundlage für qualitativ hochwertige Antworten.

Ein weiterer wesentlicher Vorteil ist die hohe Quellentreue der generierten Inhalte. Durch die Nutzung externer Wissensquellen sowie geeigneter Validierungsmechanismen wird das Risiko von Halluzinationen deutlich reduziert. Dies ist insbesondere im juristischen Kontext von entscheidender Bedeutung.

Darüber hinaus zeichnet sich das System durch eine transparente Behandlung von Unsicherheiten aus. Bei unzureichender Kontextbasis werden entsprechende Hinweise gegeben, was die Nachvollziehbarkeit und Vertrauenswürdigkeit der Antworten erhöht.

Die modulare Architektur stellt ebenfalls eine Stärke dar, da sie eine flexible Erweiterung und Anpassung des Systems ermöglicht.
Als zentrale Schwäche ist die teilweise unzureichende Vollständigkeit der Antworten zu nennen. Insbesondere bei komplexen Fragestellungen werden nicht alle relevanten Aspekte vollständig berücksichtigt. Dies ist unter anderem auf die Begrenzung der betrachteten Dokumente sowie auf die Struktur der zugrunde liegenden Wissensbasis zurückzuführen.
Zudem kann nicht vollständig ausgeschlossen werden, dass einzelne generierte Inhalte nicht vollständig durch die bereitgestellten Quellen gestützt sind. Dieses Restrisiko ist systemimmanent und stellt eine generelle Herausforderung von RAG-Systemen dar.
Ein weiterer Aspekt betrifft die teilweise hohe Ausführlichkeit der Antworten, was die Nutzerfreundlichkeit im praktischen Einsatz beeinträchtigen kann.

7.3 Limitationen

Die Aussagekraft der durchgeführten Evaluation ist durch mehrere Faktoren eingeschränkt. Der verwendete Datensatz ist vergleichsweise klein, wodurch keine belastbare statistische Absicherung der Ergebnisse möglich ist.
Darüber hinaus basiert die Bewertung der Antwortqualität ausschließlich auf einem automatisierten, modellbasierten Ansatz. Eine zusätzliche menschliche Evaluation könnte die Validität der Ergebnisse weiter erhöhen.
Ein weiterer limitierender Faktor liegt in der domänenspezifischen Ausrichtung des Systems. Die Übertragbarkeit auf andere Rechtsgebiete oder Anwendungsdomänen ist daher nur eingeschränkt gegeben.
Schließlich hängt die Leistungsfähigkeit des Systems maßgeblich von der Qualität und Vollständigkeit der zugrunde liegenden Dokumente ab. Zudem sind komplexe Fragestellungen, die ein Multi-Hop-Reasoning über mehrere Dokumente erfordern, nur eingeschränkt abbildbar.
Die genannten Limitationen verdeutlichen Ansatzpunkte für zukünftige Verbesserungen und bilden die Grundlage für weiterführende Forschungsarbeiten.

8 Fazit und Ausblick

8.1 Fazit

Die Untersuchung hatte zum Ziel, die Anwendbarkeit von Large Language Models (LLMs) in einem thematisch fokussierten Expertensystem zusammen mit hybriden Retrieval-Methoden zu bewerten. Ein Retrieval-Augmented-Generation-(RAG)-System wurde hierfür entwickelt, das eine BM25-basierte Volltextsuche mit einer semantischen Vektorsuche innerhalb von Elasticsearch kombiniert und die ermittelten Informationen zur kontextuellen Antwortgenerierung an ein Large Language Model übergibt.

Die Evaluationsergebnisse belegen, dass die Antwortqualität erheblich verbessert werden kann, wenn man Retrieval-Mechanismen und LLMs kombiniert. Gerade das Einfügen von relevanten Textabschnitten erlaubt es, die Generierung stärker zu steuern und verbessert die inhaltliche Nachvollziehbarkeit der Antworten. So kann das Risiko von Halluzinationen verringert werden, obwohl es nicht gänzlich ausgeschlossen werden kann.

Eine hybride Suchstrategie hat sich als besonders wirkungsvoll erwiesen, weil sie einerseits exakte Treffer durch lexikalische Verfahren und andererseits semantisch ähnliche Inhalte umfasst. Eine bessere Trefferqualität im Retrieval-Schritt ist das Ergebnis dessen, was wiederum eine entscheidende Grundlage für die Qualität der generierten Antworten ist.

Die Arbeit demonstriert zudem, dass ein solches System domänenspezifisches Wissen aus großen Dokumentensammlungen effizient zugänglich macht und nutzerfreundlich aufbereitet. Dies bietet einen erheblichen Vorteil, besonders wenn es um komplizierte Regelungen wie die im Vergaberecht geht.

Es wird jedoch auch offensichtlich, dass die Effizienz des Systems stark von der Qualität der zugrunde liegenden Daten, der ausgewählten Retrieval-Strategie und der Gestaltung der Prompt abhängt. Um sicherzustellen, dass die Ergebnisse verlässlich sind, ist es unerlässlich, das System sorgfältig zu konzipieren.

Es ist festzustellen, dass die Nutzung von Large Language Models zusammen mit hybriden Retrieval-Methoden grundsätzlich sinnvoll und umsetzbar ist, um die Forschungsfrage zu beantworten. Vor allem, wenn man datengestütztes Retrieval mit generativer Sprachverarbeitung kombiniert, kann man die Qualität, Nachvollziehbarkeit und Relevanz der Antworten erheblich verbessern.

Alles in allem ist Retrieval-Augmented-Generation ein vielversprechender Ansatz für den Einsatz von Large Language Models in Expertensystemen und bietet eine praktikable Möglichkeit, die Vorzüge datengetriebener Sprachmodelle mit strukturierten Wissensquellen zu vereinen.

8.2 Einschränkungen

Obwohl die Ergebnisse positiv sind, hat das entwickelte System einige Einschränkungen. Eine wesentliche Herausforderung bleibt die Möglichkeit, dass das eingesetzte Sprachmodell ungenaue oder unvollständige Antworten generiert. Selbst wenn der Einsatz von Retrieval Halluzinationen mindert, sind sie dennoch nicht vollständig zu vermeiden.
Ein weiterer begrenzender Aspekt ist die Abhängigkeit von der Qualität und dem Umfang der indexierten Dokumente. Informationen, die fehlen oder veraltet sind, beeinflussen die Qualität der Antwort direkt. Auch die Chunking-Strategie kann die Retrieval-Ergebnisse beeinflussen, weil relevante Informationen möglicherweise auf mehrere Textabschnitte verteilt sind.
Eine weitere Einschränkung ergibt sich durch den gewählten Evaluationsansatz. Die generierten Antworten werden durch ein LLM-as-a-Judge-Verfahren bewertet. Die Bewertung kann durch modellabhängige Verzerrungen beeinträchtigt werden, obwohl ein anderes Modell dafür verwendet wird. Eine komplett objektive Bewertung ist somit nicht gewährleistet.

8.3 Ausblick

Es gibt mehrere Ansatzpunkte zur Weiterentwicklung des Systems in zukünftigen Arbeiten. Eine mögliche Verbesserung besteht darin, Re-Ranking-Mechanismen einzuführen, wie etwa Cross-Encoder, um die Relevanz der abgerufenen Dokumente weiter zu steigern.
Außerdem wäre es möglich, das System um kontextbezogene Dialogfähigkeiten zu erweitern, sodass es mehrstufige Anfragen und Folgefragen verarbeiten kann. Das würde die Benutzerfreundlichkeit und die praktische Anwendbarkeit weiter verbessern.
Eine andere Herangehensweise besteht darin, die Evaluationsmethodik zu verfeinern. Um subjektive Verzerrungen zu minimieren und robustere Ergebnisse zu erzielen, wäre es hilfreich, mehrere unterschiedliche Bewertungsmodelle zu nutzen.
Schließlich gibt es ein großes Potenzial, das System auf andere Fachdomänen zu übertragen. Die ausgearbeitete Architektur ist eine gute Basis für die Entwicklung weiterer domänenspezifischer Expertensysteme, etwa im Steuerrecht, im Gesundheitswesen oder im technischen Support.
Diese Arbeit kommt zu dem Schluss, dass die Verbindung von Large Language Models mit hybriden Retrieval-Methoden ein großes Potenzial für die Schaffung von leistungsfähigen und zuverlässigen Expertensystemen hat, und dass dessen Weiterentwicklung ein vielversprechendes Forschungsfeld ist.

A Literatur

B Allgemeiner Anhang

Anstelle eines physischen Datenträgers wird der im Rahmen dieser Arbeit entwickelte Quellcode über ein öffentlich zugängliches GitHub-Repository bereitgestellt.

Repository:
https://github.com/etalom/Bachelorarbeit

Das Repository enthält den vollständigen Quellcode des entwickelten Systems, die im Rahmen der Evaluation verwendeten Skripte sowie weitere projektrelevante Dateien und Ressourcen. Dadurch wird eine transparente Nachvollziehbarkeit und Reproduzierbarkeit der Ergebnisse gewährleistet.